

面向任务自适应红外与可见光图像融合的共生进化学习^{*}

刘晋源¹, 张博为¹, 孙鲁丹¹, 李星源², 马 龙¹, 刘日升¹, 樊 鑫¹

¹(大连理工大学软件学院, 辽宁大连 116024)

²(浙江大学计算机科学与技术学院, 浙江杭州 310027)

通讯作者: 樊鑫, E-mail: xin.fan@dlut.edu.cn

摘要 红外与可见光图像融合 (infrared and visible image fusion, IVIF) 旨在将热目标显著性与丰富纹理整合到单幅图像中, 使融合结果既具有良好的视觉质量, 又有利于下游视觉任务。然而, 依赖启发式视觉准则的传统方法难以保证任务效用; 任务驱动的融合范式通常采用固定权重标量化, 不同异构任务间潜在的目标冲突会导致僵化折中, 并在多任务场景中产生次优泛化性能。为突破上述瓶颈, 提出一种面向任务自适应 IVIF 的共生进化学习框架 EvoFuse。该方法不依赖静态损失权重, 而是从多目标视角刻画融合与感知之间的关联。为在结构上实现这一建模, 首先设计一种可重参数化融合架构: 训练时利用多分支结构提供较强的表征能力, 推理时则可解析折叠为超紧凑的单分支模型, 从而实现高效推理。为协调相互冲突的多任务目标, 引入进化搜索机制, 动态演化任务感知的损失权重配置; 在受 Pareto 思想启发的非退化准则下, 融合网络与任务模型得以共同更新并相互适应。此外, 设计了一种新的显著性判别损失, 以显式强调语义关键区域。在涵盖图像融合及下游感知任务的 11 个数据集上进行的大量实验表明, 在所考察的任务设置下, 所提方法在大多数评价指标上取得了有竞争力或更优的结果, 同时保持了较高的推理效率。

关键词 图像融合; 红外与可见光; 进化学习; 多目标优化; 任务自适应

1 引言

为构建能够在复杂环境中稳定工作的鲁棒感知系统, 红外与可见光图像融合已成为计算机视觉中的一项关键技术 [1]。其目标是合成超越任一单一模态局限的综合表征 [2]: 一方面利用红外传感器对光照变化和低能见度具有较强鲁棒性的热辐射信息, 另一方面保留可见光谱所包含的丰富纹理细节和较高空间分辨率。因此, 融合图像能够提供更全面的场景理解 [3]。可靠的多模态图像融合已成为持续监控、全天候自动驾驶和场景语义解析等重要下游应用不可或缺的环节 [4]。

在实际需求的推动下, 相关研究取得了显著进展, 大体可分为两个发展阶段 [5]。第一阶段较为成熟, 主要关注视觉保真度 [6]。大量深度学习方法通过启发式设计的重建损失生成高质量融合图像 [7]。然而, 这类方法主要面向人类视觉感知或像素级统计指标进行优化 [8], 忽视了机器视觉对特征表征的需求 [9]。因此, 视觉上较为美观的图像往往不能保证对下游语义任务具有可靠效用。针对这一根本缺




图 1 本文策略 (右) 与面向任务的联合优化 (左) 之动机差异。面向任务的联合优化依赖人工加权的联合梯度更新参数, 可能使优化偏向单一任务最优点; 本文策略则演化候选更新方向, 并依据 Pareto 偏好选择有效方向, 从而在多个任务之间实现自适应平衡。

口, 新近的第二阶段研究开始探索任务驱动的融合范式 [10]。这类工作通过多任务学习, 尝试将融合网络与目标检测、语义分割等下游视觉任务紧密耦合 [11], 是从视觉导向迈向任务导向的重要进展。

然而, 新兴的多任务范式往往采用简单的预定义权重配置来聚合相互竞争的目标 [12]。这种固定权重标量化机制低估了不同下游任务固有的异构性。不同感知任务关注的语义粒度和特征分布不同 [13], 在训练过程中会向共享融合网络施加复杂且高度冲突的梯度方向 [14, 15]。刚性的静态权重配置只能形成经验性折中: 某一任务性能的提升往往会严重损害视觉保真度或其他感知任务的效用。由于优化轨迹被预定义标量严格限制, 这类方法容易陷入次优局部极小值, 难以在不同场景中实现真正的多任务泛化 [16]。尽管近期任务导向方法尝试通过自适应加权或分阶段学习处理多目标优化, 其优化过程仍受部分学习所得或人工固定系数的约束 [17, 18]。因此, 视觉保真度与异构任务效用之间的冲突仍未得到充分解决, 亟需在不同下游任务间动态搜索更有利的折中方案。

为解决上述根本矛盾并充分挖掘异构任务间的协同潜力, 本文提出面向任务自适应红外与可见光图像融合的共生进化学习框架 EvoFuse, 其训练策略如图1所示。本文的核心思想是摆脱静态标量化, 从多目标优化角度重新刻画融合与感知之间的关联。为连接理论建模与实际系统, 框架包含两项相互协同的设计。在结构层面, 设计可重参数化融合网络——多样重加权架构 (diverse reweight architecture, DRA)。训练时将其展开为多分支拓扑, 以吸收不同表征监督并容纳相互冲突的多任务梯度; 推理时将其解析折叠为极紧凑的单分支模型, 不引入额外部署开销。在算法层面, 针对高度非凸且存在任务冲突的目标空间, 提出受 Pareto 偏好启发的进化搜索策略。该策略将损失权重配置参数化为主动演化的种群, 持续评估验证反馈并动态调整任务权重, 从而建立融合策略与任务模型共同演化、相互适应的过程, 趋向于减少任务退化的折中解。此外, 设计新的显著性判别损失, 显式强调语义关键区域, 在维持下游任务效用的同时促进显著视觉线索的保留。

本文的主要贡献如下。

- 建立连接红外与可见光图像融合及多种下游任务的共生多目标模型。融合不再被视为孤立的预处理步骤, 视觉保真目标与异构感知目标被统一建模于同一优化框架中。
- 将该模型展开为可高效部署的可重参数化轻量框架。其中, DRA 在训练阶段为多目标学习提供

多分支表征能力, 在推理阶段则可解析折叠为紧凑的单分支模型.

- 提出求解上述多目标优化问题的共生进化学习策略. 通过演化损失权重配置, 该策略在异构任务冲突下自适应探索有效更新方向, 从而在融合质量与综合任务效用之间获得有利折中.
- 在多种任务上开展了大量定量与定性实验. 结果表明, 所提轻量融合模型在多个数据集的视觉质量和感知性能评价中达到领先水平.

2 相关工作

2.1 面向视觉质量的图像融合

近年来, 基于深度学习的红外与可见光图像融合方法得到广泛研究 [19, 20]. 早期方法通常使用自编码器学习模态特有的潜在特征, 在表征空间中融合这些特征, 再重建融合图像 [21]. 例如, DenseFuse [22, 23] 首先利用自编码器学习通用图像特征表征, 随后在测试阶段进行特征级融合并重建图像. 后续研究逐渐采用卷积神经网络 [24] 和 Transformer [7] 架构, 以更好地建模局部结构和长程依赖. YDTR [25] 通过 Y 形双分支网络分别提取红外与可见光特征, 并使用动态 Transformer 模块同时建模局部细节和全局上下文, 实现端到端融合. 基于生成对抗网络 (GAN) 的框架 [26, 27] 也被用于对齐融合输出与真实图像的分布, 并约束生成图像的统计特性. FreqGAN [28] 利用离散小波变换将图像特征分解为低频和高频分量, 采用双判别器对不同频带进行自适应加权, 实现频率感知融合. 近期, 得益于训练稳定性和较强生成能力, 扩散模型 [29, 30] 成为另一类生成范式. DDFM [31] 将图像融合表述为扩散模型中的条件生成问题, 利用预训练 DDPM 提供图像先验, 并在采样过程中通过似然校正注入源图像信息, 从而生成高质量融合图像. 尽管取得了上述进展, 许多方法主要依赖低层约束而未显式建模语义结构, 因而对下游任务的增益有限 [10]. 同时, 亮度保持、梯度保持等损失之间的相对权重仍难以确定, 并会影响方法在不同场景中的鲁棒性.

2.2 面向任务的图像融合

为提高下游任务效能, 近期研究将融合网络与特定任务模型相耦合 [32]. 一种典型策略是将融合网络连接到语义分割模型, 使分割监督能够反向传播到融合模块, 促进任务相关结构的保留 [9]. MRFS [16] 采用共享编码器和两个解码头, 在语义感知框架中统一图像融合与分割, 通过视觉特征补全和语义特征聚合的相互增强, 同时改善融合图像质量和下游语义理解. 除分割驱动设计外, 部分研究在融合模块后连接目标检测网络, 利用目标级监督信号促使融合表征更符合检测需求 [12]. DetFusion [33] 构建检测驱动的融合框架, 利用目标位置先验和检测损失引导融合网络生成更有利于目标检测的图像. 然而, 引入任务网络通常会增加额外的损失项和优化目标, 提高优化复杂度, 使训练过程中多种损失之间的折中更难控制.

训练时, 不同损失项常以经验选取的权重组合, 用于协调各个目标 [3, 34]. 这种标量化将多目标问题转化为单个加权目标, 但固定权重往往难以适应数据分布和场景变化 [6]. 为缓解该问题, PIAFusion [35] 通过估计光照概率并据此构建光照感知损失, 提出光照感知优化策略, 在不同亮度条件下自适应引导融合网络; 但额外的条件估计可能引入新的优化不稳定性. MetaFusion [36] 先预训练融合网络, 再基于融合输出微调检测器, 并交替更新两个模型以提高联合性能; 这种多阶段流程增加了计算开销, 并可能限制端到端联合最优性. BDLFusion [17] 采用双层动态学习调节融合目标与分




图 2 所提共生进化学习框架概览. 该框架将图像融合与下游感知重新表述为任务自适应多目标优化问题. 融合网络为多个下游任务模型生成融合图像, 迭代式任务自适应学习策略交替更新任务模型与融合模型. 借助对任务感知权重配置的进化搜索, 优化过程逐步趋向于视觉保真度与异构任务效用之间具有 Pareto 偏好的折中解.

割目标的相对贡献, 但其融合损失仍包含固定系数项. TDFusion [18] 通过由内、外层任务损失更新驱动的损失生成模块学习融合损失参数, 但仍保留人工设置的系数来平衡亮度项与梯度项.

2.3 面向多目标优化的进化学习

进化学习能够灵活融入领域知识, 因此常被用作多目标优化问题的求解器 [11, 37, 38]. 例如, EMOMC [39] 提出进化多目标模型压缩方法, 联合优化剪枝与量化, 得到在准确率、能耗和模型规模之间具有 Pareto 偏好的边缘模型. 进化学习也被用于学习任务卸载策略的 Pareto 偏好解, 以平衡多个目标 [40, 41]. CENAS [42] 利用 Pareto 排序分类器引导多目标进化神经架构搜索 (NAS), 寻找兼顾准确率、浮点运算量 (FLOPs) 和参数量的网络架构. 基于分解的多目标进化优化 [43] 还被用于自适应算子选择, 以提高收敛性和优化性能. DCEvo [11] 利用进化学习自适应优化图像融合与单个下游任务之间的损失折中, 但其级联设计主要在单一任务分支内搜索任务特定的折中, 难以协调多个异构下游任务之间相互竞争的需求. 不同于这一单任务设置, 本文框架在一个任务目标下执行进化学习, 同时利用其他任务模型评价候选融合更新, 并进一步结合迭代式任务适应, 实现融合网络与多个下游任务之间的共生优化.

3 所提方法

所提共生进化学习框架的总体流程如图2所示. 本文不再将图像融合与下游感知视为彼此独立的范式, 而是将二者的关联表述为任务自适应多目标优化 (multi-objective optimization, MOO) 问题 (第3.1节). 在该理论模型指导下, 设计一种可重参数化融合架构, 训练时可灵活容纳相互冲突的多任务梯度, 推理时可折叠为轻量结构 (第3.2节). 为在多个任务之间获得理想折中, 提出迭代式任务自适应学习策略, 通过跨任务的迭代优化与交互实现逐任务适应 (第3.3节). 为有效搜索高度非凸的目标空间, 进一步提出进化学习算法, 动态寻找具有 Pareto 偏好的折中解 (第3.4节). 驱动进化搜索的具体损失函数见第3.5节.




图 3 所提轻量融合网络结构. 网络包含深层特征提取路径和多尺度恒等路径. 训练阶段引入 DRA 模块以增强多频表征, 推理阶段将其重参数化为紧凑的单分支形式, 以实现高效部署.

3.1 问题建模

给定配准的红外图像 $\mathbf{I}_{\text{ir}} \in \mathbb{R}^{H \times W \times C_{\text{ir}}}$ 与可见光图像 $\mathbf{I}_{\text{vi}} \in \mathbb{R}^{H \times W \times C_{\text{vi}}}$, 由权重向量 $\boldsymbol{\theta}$ 参数化的图像融合网络 $\mathcal{F}_{\boldsymbol{\theta}}$ 的基本目标是生成融合图像 $\mathbf{I}_{\text{fus}} = \mathcal{F}_{\boldsymbol{\theta}}(\mathbf{I}_{\text{ir}}, \mathbf{I}_{\text{vi}})$.

传统上, 融合网络通过启发式设计的视觉保真损失 $\mathcal{L}_{\text{fus}}(\boldsymbol{\theta})$ 进行优化. 当融合模型需要服务于 K 个不同的下游感知任务 (如目标检测、语义分割) 时, 优化目标具有内在异构性. 设 $\mathcal{T}_k$ 表示由 ϕ_k 参数化的第 k 个下游任务网络, $\mathcal{L}_{\mathcal{T}_k}(\boldsymbol{\theta}, \phi_k)$ 表示相应的任务特定损失. 传统多任务训练范式依赖经验性标量化方法, 使用预定义的静态权重向量 $\mathbf{w} = [w_0, w_1, \dots, w_K]^\top \in \mathbb{R}^{K+1}$:

$$\min_{\boldsymbol{\theta}, \Phi} \mathcal{J}(\boldsymbol{\theta}, \Phi) = w_0 \mathcal{L}_{\text{fus}}(\boldsymbol{\theta}) + \sum_{k=1}^K w_k \mathcal{L}_{\mathcal{T}_k}(\boldsymbol{\theta}, \phi_k), \quad (1)$$

其中, $\Phi = \{\phi_1, \dots, \phi_K\}$ 为所有任务网络的参数集合. 这种静态聚合存在一个关键局限: 异构下游任务会向共享融合网络 $\mathcal{F}_{\boldsymbol{\theta}}$ 施加内在冲突的梯度方向. 固定权重配置缺乏任务自适应性, 会形成刚性折中, 使某一任务性能的提升往往严重损害视觉保真度或其他任务效用.

为突破上述瓶颈, 本文摒弃固定权重标量化, 将融合与感知之间的关联重新表述为任务自适应多目标优化问题. 具体而言, 将融合网络与下游任务的优化视为相互适应过程, 以同时最小化向量值目标函数 $\mathbf{L}$. 为简化记号, 目标向量写为:

$$\min_{\boldsymbol{\theta}} \mathbf{L}(\boldsymbol{\theta}, \Phi^*) = \left[\mathcal{L}_{\text{fus}}(\boldsymbol{\theta}), \mathcal{L}_{\mathcal{T}_1}(\boldsymbol{\theta}, \phi_1^*), \dots, \mathcal{L}_{\mathcal{T}_K}(\boldsymbol{\theta}, \phi_K^*) \right]^\top, \quad (2)$$

其中, $\Phi^* = \{\phi_1^*, \dots, \phi_K^*\}$ 表示动态适应当前融合图像分布 $\mathbf{I}_{\text{fus}}$ 的下游任务网络最优参数集合. 进一步简记目标向量为 $\mathbf{L}(\boldsymbol{\theta}) = [\mathcal{L}_0(\boldsymbol{\theta}), \mathcal{L}_1(\boldsymbol{\theta}), \dots, \mathcal{L}_K(\boldsymbol{\theta})]^\top$, 其中 $\mathcal{L}_0$ 表示融合损失, $\mathcal{L}_{1 \dots K}$ 表示任务损失. 在这一异构多目标背景下, 通常难以获得能够同时最小化 $\mathbf{L}(\boldsymbol{\theta})$ 全部分量的单一绝对最优解 $\boldsymbol{\theta}$. 该建模引导融合网络在视觉保真度与下游任务效用之间趋向具有 Pareto 偏好的折中. 具体而言, Pareto 最优性启发了本文由验证集引导的非退化准则, 用于选择能够保持或改善下游任务性能的融合更新.

定义 1(Pareto 最优性). 若不存在其他可行参数 θ , 使得对所有 $i \in \{0, 1, \dots, K\}$ 均有 $\mathcal{L}_i(\theta) \leq \mathcal{L}_i(\theta^*)$, 且至少对一个下标 j 满足 $\mathcal{L}_j(\theta) < \mathcal{L}_j(\theta^*)$, 则称参数向量 θ^* 为 Pareto 最优.

由于高度非凸的深度网络难以解析推导真实 Pareto 前沿, 式 (2) 作为指导性模型, 而非具有闭式解的目标. 接下来的问题是设计一种实际机制, 自适应探索视觉保真度与异构任务效用之间具有 Pareto 偏好的折中. 为此, 本文设计任务自适应融合架构, 并提出由具体融合损失和感知损失驱动的进化学习策略.

3.2 将模型展开为轻量融合网络

为从结构上实现上述多目标模型, 融合网络在训练时需要具备足够的表征能力, 以承受高度异构的多任务梯度; 同时, 推理时又必须保持极度轻量, 以保证在边缘设备上实时部署. 为协调这一内在矛盾, 本文将多目标模型展开为结构可重参数化的轻量框架.

如图3所示, 所提架构是相互适应过程的结构基础. 设 $\mathbf{I}_{\text{ir}}$ 和 $\mathbf{I}_{\text{vi}}$ 分别表示严格配准的红外与可见光源图像, 沿通道维拼接得到输入张量 $\mathbf{X}$. 整体融合映射被显式解耦为双流拓扑:

$$\mathbf{I}_{\text{fus}} = \mathcal{R}(\mathbf{X}) + \mathcal{D}(\mathbf{X}), \quad (3)$$

其中, $\mathcal{D}(\cdot)$ 表示由级联 DRA 模块参数化的深层特征提取映射, $\mathcal{R}(\cdot)$ 表示由多尺度残差模块构成的全局结构整合路径.

1) 多样重加权架构 (DRA). 为保证足够的表征多样性以吸收相互冲突的多任务梯度, 训练阶段将常规卷积层在结构上扩展为多分支 DRA 模块. 定义异构卷积核集合 $\mathcal{K} = \{1 \times 1, 2 \times 2, 3 \times 3, 1 \times 3, 3 \times 1\}$, 显式建模不同频率分量和空间先验.

设 $\mathbf{F} \in \mathbb{R}^{C_{\text{in}} \times H \times W}$ 为输入中间特征图. 对每个分支 $\kappa \in \mathcal{K}$, $\mathbf{W}_{\kappa}$ 和 $\mathbf{b}_{\kappa}$ 分别表示可训练权重张量和偏置向量. DRA 模块在训练阶段的前向传播不采用多层操作嵌套, 而定义为逐通道缩放求和:

$$\mathbf{F}_o = \sigma \left(\mathbf{w} \odot \sum_{\kappa \in \mathcal{K}} \left(\mathbf{W}_{\kappa} * \mathbf{F} + \mathbf{b}_{\kappa} \right) \right), \quad (4)$$

其中, $*$ 表示二维互相关算子, $\sigma(\cdot)$ 表示非线性激活函数 ReLU, $\mathbf{w} \in \mathbb{R}^{C_{\text{out}} \times 1 \times 1}$ 为可训练的分支重加权向量, 通过逐通道 Hadamard 积 $\odot$ 对聚合后的多频特征进行自适应重标定.

为实现零额外开销部署, 推理阶段将该多分支拓扑解析折叠为超紧凑的单卷积层. 利用线性卷积算子的可加性, 复杂的合并过程可在数学上简化为一次张量聚合:

$$\mathbf{W}_{\text{fuse}} = \mathbf{w} \odot \sum_{\kappa \in \mathcal{K}} \widehat{\mathbf{W}}_{\kappa}, \quad \mathbf{b}_{\text{fuse}} = \mathbf{w} \odot \sum_{\kappa \in \mathcal{K}} \mathbf{b}_{\kappa}, \quad (5)$$

其中, $\widehat{\mathbf{W}}_{\kappa} \in \mathbb{R}^{C_{\text{out}} \times C_{\text{in}} \times 3 \times 3}$ 表示原卷积核 $\mathbf{W}_{\kappa}$ 经精确边界补零后在结构上对齐的形式. 具体而言, $\widehat{\mathbf{W}}_{1 \times 1}$ 在各空间边界对称填充 1 个像素, 而 $\widehat{\mathbf{W}}_{1 \times 3}$ 等非对称卷积核则选择性填充到统一的 3×3 尺寸. 因此, 推理阶段的复合前向传播可化为单一操作 $\mathbf{F}_o = \sigma(\mathbf{W}_{\text{fuse}} * \mathbf{F} + \mathbf{b}_{\text{fuse}})$. 这一严格的数学等价性保证网络精确保留训练阶段优化所得的强大表征能力, 同时在部署时不产生任何结构性额外开销.

2) 多尺度残差 (MSR). 为在不受深层特征失真的情况下严格保留源模态中的关键结构保真度和显著强度分布, 将 MSR 结构 $\mathcal{R}(\cdot)$ 设计为直接的多尺度恒等路径. 设 $\mathcal{S} = \{1, 3, 5, 7\}$ 为感受野尺度集

算法 1 迭代式任务自适应学习

输入： 源模态图像 $\mathbf{I}_{vi}, \mathbf{I}_{ir}$ ；初始化融合模型 θ^0 ；初始化的多个下游任务模型 $\{\phi_k^0\}_{k=1}^K$ ；总迭代次数 T

输出： 优化后的融合模型和任务模型 $\theta^T, \{\phi_k^T\}_{k=1}^K$

```

1: for  $t = 1$  到  $T$  do
2:   根据式 (7), 使用当前融合模型  $\theta^{t-1}$  生成融合图像  $\mathbf{I}_{fus}^{t-1}$ 
3:   for  $k = 1$  到  $K$  do
4:     根据式 (8), 在当前融合图像  $\mathbf{I}_{fus}^{t-1}$  的分布上训练第  $k$  个下游任务模型  $\phi_k^t$ 
5:   end for
6:   在  $\mathbf{I}_{fus}^{t-1}$  上评价更新后的任务模型  $\{\phi_k^t\}_{k=1}^K$ , 得到任务感知评价指标
7:   for  $k = 1$  到  $K$  do
8:     采用第3.4节所述带 Pareto 偏好非退化准则的进化搜索, 细化融合模型  $\theta^{t-1}$ 
9:   end for
10:  得到更新后的融合模型  $\theta^t$ 
11: end for
12: 返回  $\theta^T$  和  $\{\phi_k^T\}_{k=1}^K$ 
    
```

合, 多尺度残差聚合对称地表示为:

$$\mathcal{R}(\mathbf{X}) = \sum_{s \in \mathcal{S}} \psi_s(\mathbf{X}), \quad (6)$$

其中, ψ_s 表示采用 $s \times s$ 方形卷积核的卷积层. 遵循 DRA 模块相同的解析折叠思想, 推理阶段将这些不同的多尺度恒等分支在数学上重参数化为单个 7×7 卷积层 ψ_{fuse} . 这种结构展开策略使网络在训练时具有较大的参数空间, 可联合优化互补特征流; 最终又可折叠为极精简架构, 实现快速感知.

3.3 迭代式任务自适应学习

为训练能够服务多个任务的融合模型, 一种直接的方法是基于式 (1) 联合优化融合模型与全部下游任务模型. 这种联合优化范式使融合过程同时接受视觉质量目标和任务导向监督信号的直接引导, 从而使网络能够捕获上游融合与下游感知之间的内在依赖.

然而, 式 (1) 面临的主要挑战在于: 不同下游任务通常对融合图像施加异构甚至相互冲突的偏好. 使用人工设计的固定系数直接优化全部目标往往只能得到次优结果, 并可能使融合模型偏向少数任务, 限制联合优化潜力的充分发挥. 为此, 本文将任务平衡系数视为自适应优化变量, 通过进化策略搜索有效更新方向.

所提框架采用迭代优化范式. 在第 t 次迭代中, 当前融合模型 θ^{t-1} 首先生成融合图像:

$$\mathbf{I}_{fus}^{t-1} = \mathcal{F}_{\theta^{t-1}}(\mathbf{I}_{ir}, \mathbf{I}_{vi}), \quad (7)$$

其中, θ^0 通过仅使用视觉质量约束预训练融合网络得到. 基于生成的融合图像 $\mathbf{I}_{fus}^{t-1}$, 分别优化各下游任务模型, 使其适应当前融合分布:

$$\phi_k^t = \arg \min_{\phi_k} \mathcal{L}_{\mathcal{T}_k}^{\text{train}}(\theta^{t-1}, \phi_k), \quad k = 1, 2, \dots, K. \quad (8)$$




图 4 单任务上的共生进化学习框架。利用验证适应度评价候选超参数向量种群，通过交叉和变异演化选中个体。经过若干进化轮次后，由最佳个体更新融合模型，引导优化趋向融合质量与任务性能之间的有利折中。

由此，下游任务模型不再是固定的外部评价器，而是与融合模型一同逐步更新。任务模型可作为任务感知的感知判别器，持续提供针对当前融合图像分布的反馈。整体过程见算法1。

得到更新后的任务模型 $\{\phi_k^t\}_{k=1}^K$ 后，在其联合引导下进一步细化融合模型。本文不直接为全部目标使用固定系数，而是引入第3.4节所述的进化搜索机制，自适应确定有利于融合模型的优化方向，使融合网络朝着同时有益于多个下游任务的解演化。为保证更新后的融合模型不会降低下游感知性能，施加如下受 Pareto 思想启发的非退化准则：

$$\mathcal{A}_k^{\text{val}}(\theta^t, \phi_k^t) \geq \mathcal{A}_k^{\text{val}}(\theta^{t-1}, \phi_k^t), \quad k = 1, 2, \dots, K, \quad (9)$$

其中， $\mathcal{A}_k^{\text{val}}(\theta, \phi_k)$ 表示使用参数 ϕ_k 时，由 θ 生成的融合图像 $\mathbf{I}_{\text{fus}}$ 在任务 $\mathcal{T}_k$ 上的验证准确率。若不满足上述约束，则令 $\theta^t = \theta^{t-1}$ 。该约束促使进化学习在搜索模型 θ^t 时保持或改善全部下游任务的性能，从而保证优化后的融合模型是具有 Pareto 偏好的解。

3.4 单任务上的共生进化学习

算法1的关键挑战是在视觉约束与多样感知表征之间寻找最优解。在图像融合与下游任务的联合优化中，由于目标相互冲突，传统方法容易出现不稳定并收敛于次优局部解。因此，本文针对一个选定任务优化融合模型，同时引入多个任务特定模型作为判别器，使当前任务得到改善而不降低其他任务的感知性能；其中，利用进化学习为复杂多任务优化探索更广泛的解空间。进化学习过程如图4所示。

为提高任务适应能力，将融合模型的优化方向编码为超参数向量：

$$\mathbf{x} = \left[\mathbf{x}_{\text{fus}}^\top, \mathbf{x}_{\mathcal{T}_k}^\top \right]^\top, \quad (10)$$

其中， $\mathbf{x}_{\text{fus}}$ 控制面向融合的损失权重， $\mathbf{x}_{\mathcal{T}_k}$ 控制任务 $\mathcal{T}_k$ 的感知损失权重。给定候选超参数向量 $\mathbf{x}$ ，融合模型在任务 $\mathcal{T}_k$ 上按下式更新：

$$\theta^t = \arg \min_{\theta} \left[\mathbf{x}_{\text{fus}}^\top \mathcal{L}_{\text{fus}}^{\text{train}}(\theta) + \mathbf{x}_{\mathcal{T}_k}^\top \mathcal{L}_{\mathcal{T}_k}^{\text{train}}(\theta, \phi_k^t) \right], \quad (11)$$

其中， $\mathcal{L}_{\mathcal{T}_k}^{\text{train}}$ 为任务 $\mathcal{T}_k$ 的训练损失。实际中，每个候选向量 $\mathbf{x}$ 对应视觉保真度与任务目标之间的一种可能折中。通过评价由这些候选方向构成的种群，所提框架避免使用人工固定标量化，转而探索更广泛的优化轨迹，使融合模型在保持视觉质量的同时朝更有利于下游感知的方向更新。

为实现式 (11) 中的自适应搜索, 设计基于种群的进化学习策略. 在第 t 次外层迭代的第 e 个进化轮次中, 维护种群 $\mathcal{P}^{t,e} = \{\mathbf{x}^{t,e,n}\}_{n=1}^N$ 包含 N 个个体, 每个个体 $\mathbf{x}^{t,e,n} \in \mathbb{R}^d$ 表示一个候选优化方向, d 为超参数总数. 对于每个个体 $\mathbf{x}^{t,e,n}$, 从进化学习初始检查点 $\boldsymbol{\theta}^{t,*}$ 出发优化融合模型, 并执行一步梯度更新:

$$\boldsymbol{\theta}^{t,e,n} = \boldsymbol{\theta}^{t,*} - \eta^{t,e} \nabla_{\boldsymbol{\theta}} \mathbf{x}^{t,e,n \top} \cdot (\mathcal{L}_{\text{fus}}^{\text{train}}, \mathcal{L}_{\mathcal{T}_k}^{\text{train}})^{\top}, \quad (12)$$

其中, $\eta^{t,e}$ 表示学习率. 为实现平滑收敛并减小优化振荡, 采用线性递减学习率 $\eta^{t,e} = \eta_0 \cdot \frac{E-e}{E}$. 需要指出, 式 (12) 仅执行临时的一步试探更新来评价各搜索方向, 而非对最终融合模型进行累积更新. 对于每个任务 $\mathcal{T}_k$, 进化搜索最终依据验证集引导的非退化准则至多提交一次选中的更新; 否则融合模型保持不变.

为评价个体 $\mathbf{x}^{t,e,n}$, 首先将融合模型更新为 $\boldsymbol{\theta}^{t,e,n}$ 并生成相应融合图像 $\mathbf{I}_{\text{fus}}^{t,e,n}$, 随后由全部任务模型在验证集上评价该候选解的任务效能. 以所有任务的平均验证准确率作为适应度分数:

$$f^{t,e,n} = \frac{1}{K} \sum_{k=1}^K \mathcal{A}_k^{\text{val}}(\boldsymbol{\theta}^{t,e,n}, \boldsymbol{\phi}_k^t). \quad (13)$$

该分数并非固定标量化训练目标, 而是验证层面的进化候选更新选择准则. 由于 Pareto 支配的候选解必然具有更高的平均验证准确率, 该准则与 Pareto 偏好一致. 结合式 (9) 的非退化准则, 式 (13) 促使融合模型朝具有 Pareto 偏好的更新方向演化, 在不牺牲单个下游任务的前提下提高整体任务效用. 据此, 选择适应度最高的两个个体作为后续进化操作的父代候选, 并将最佳个体记为:

$$\mathbf{x}^{t,e,*} = \arg \max_{\mathbf{x}^{t,e,n} \in \mathcal{P}^{t,e}} f^{t,e,n}. \quad (14)$$

基于选中的父代个体, 进化算法通过交叉和变异生成子代种群 $\tilde{\mathcal{P}}_{\text{evo}}^{t,e}$. 为平衡对历史有效方向的利用与对新候选解的探索, 进一步引入动量式种群继承机制. 设 $\mathcal{P}_{\text{rand}}^{t,e+1}$ 为随机采样种群, 则下一进化轮次的种群为:

$$\mathcal{P}^{t,e+1} = \beta \cdot \mathcal{P}_{\text{rand}}^{t,e+1} + (1 - \beta) \cdot \tilde{\mathcal{P}}_{\text{evo}}^{t,e}, \quad \beta \in (0, 1), \quad (15)$$

其中, β 控制继承程度.

经过 E 个进化轮次后, 得到最有效的融合模型 $\boldsymbol{\theta}^{t,*}$. 该模型作为其他任务上下一次进化学习或下一外层迭代的初始化. 通过上述进化学习, 所提框架获得同时改善任务效能和视觉质量的 Pareto 偏好解.

3.5 融合与任务损失函数

驱动优化的视觉约束 $\mathcal{L}_{\text{fus}}$ 与任务感知约束 $\mathcal{L}_{\mathcal{T}_k}$ 定义如下.

为在融合优化过程中保持视觉保真度, 对融合图像施加多个互补约束. 设 $\mathbf{I}_{\text{fus}}$ 为融合图像, 融合质量损失定义为:

$$\mathcal{L}_{\text{fus}} = (\mathcal{L}_{\text{grad}}, \mathcal{L}_{\text{MSE}}, \mathcal{L}_{\text{SSIM}}, \mathcal{L}_{\text{int}}, \mathcal{L}_{\text{sdl}})^{\top}, \quad (16)$$

其中, $\mathcal{L}_{\text{grad}}$ 、 $\mathcal{L}_{\text{MSE}}$ 、 $\mathcal{L}_{\text{SSIM}}$ 和 $\mathcal{L}_{\text{int}}$ 采用与文献 [11] 相同的配置.

除全局强度和梯度约束外, 融合优化还应强调潜在显著区域, 这些区域通常包含任务相关目标和高对比度结构. 现有显著性引导约束往往需要额外的显著性检测器生成显著图, 会引入额外计算与潜

在检测误差. 为避免这种依赖, 设计一种直接从图像提取显著表征的显著性判别损失. 给定图像 $\mathbf{I}$, 首先估计其相对于周围上下文的相对激活:

$$\hat{\mathbf{I}} = \sigma\left(\frac{\sigma(\mathbf{I})^2}{\mu(\sigma(\mathbf{I}))}\right), \quad (17)$$

其中, $\sigma(\cdot)$ 表示 Sigmoid 函数, $\mu(\cdot)$ 表示上下文平均算子. 该式增强相对于周围上下文响应较强的像素, 并抑制辨识度较弱的区域.

为捕获不同空间上下文中的显著响应, 分别以水平、垂直和双向上下文平均算子 $\mu_{\text{hor}}(\cdot)$ 、 $\mu_{\text{ver}}(\cdot)$ 和 $\mu_{\text{hor,ver}}(\cdot)$ 替换 $\mu(\cdot)$, 计算 3 幅调制图. 相应激活比图分别记为 $\hat{\mathbf{I}}_{\text{hor}}$ 、 $\hat{\mathbf{I}}_{\text{ver}}$ 和 $\hat{\mathbf{I}}_{\text{hor,ver}}$. 将这些图相乘形成联合调制图, 突出在不同方向上均保持显著的响应. 由此得到显著表征:

$$\tilde{\mathbf{I}} = \text{SiLU}\left(\mathbf{I} \cdot \left(\hat{\mathbf{I}}_{\text{hor}} \cdot \hat{\mathbf{I}}_{\text{ver}} \cdot \hat{\mathbf{I}}_{\text{hor,ver}}\right)\right), \quad (18)$$

其中, $\text{SiLU}(\cdot)$ 提供平滑非线性增强, $\tilde{\mathbf{I}}$ 表示由 $\mathbf{I}$ 得到的显著表征. 以相同方式分别从红外和可见光输入得到 $\tilde{\mathbf{I}}_{\text{ir}}$ 与 $\tilde{\mathbf{I}}_{\text{vi}}$. 显著性判别损失定义为:

$$\mathcal{L}_{\text{sdl}} = \|\tilde{\mathbf{I}}_{\text{vi}} - \mathbf{I}_{\text{fus}}\|_1 + \|\tilde{\mathbf{I}}_{\text{ir}} - \mathbf{I}_{\text{fus}}\|_1. \quad (19)$$

该损失促使融合图像保留两种模态的显著结构, 使模型无需外部显著性检测器或预计算显著图即可关注潜在显著区域.

多类别目标检测 (OD) 部分的损失函数由 3 项组成:

$$\mathcal{L}_{\text{OD}} = (\mathcal{L}_{\text{CE}}, \mathcal{L}_{\text{CIoU}}, \mathcal{L}_{\text{DF}})^{\top}, \quad (20)$$

其中, $\mathcal{L}_{\text{CE}}$ 、 $\mathcal{L}_{\text{CIoU}}$ 和 $\mathcal{L}_{\text{DF}}$ 分别表示交叉熵损失、完整 IoU (CIoU) 损失和分布焦点损失. 实现细节见 Ultralytics 工具 [44].

图像语义分割 (SS) 任务采用逐像素交叉熵损失:

$$\mathcal{L}_{\text{SS}} = - \sum_{p=1}^{H \times W} \sum_{i=1}^{N_{\text{cls}}} y_{p,i} \log \frac{e^{\hat{y}_{p,i}}}{\sum_{j=1}^{N_{\text{cls}}} e^{\hat{y}_{p,j}}}, \quad (21)$$

其中, H 和 W 分别表示分割图的高与宽, N_{cls} 为语义类别数. $y_{p,i} \in \{0, 1\}$ 为独热真实标签, 表示像素 p 是否属于类别 i ; $\hat{y}_{p,i} \in \mathbb{R}$ 为 Softmax 操作前对像素 p 和类别 i 预测的 logit. 对数项计算正确类别的负对数概率.

遵循采用加权 BCE 与加权 IoU 损失的显著目标检测 (SOD) 方法 [45], 显著目标检测部分的损失函数为:

$$\mathcal{L}_{\text{SOD}} = (\mathcal{L}_{\text{BCE}}, \mathcal{L}_{\text{IoU}})^{\top}, \quad (22)$$

其中, $\mathcal{L}_{\text{BCE}}$ 提供像素级监督并强调边界或困难像素, $\mathcal{L}_{\text{IoU}}$ 则通过优化预测显著图与真实掩模之间的重叠, 促进区域级结构一致性.

4 结论

提出一种面向任务自适应红外与可见光图像融合的共生进化学习框架. 该方法将融合与下游感知表述为任务自适应多目标优化问题, 并通过可重参数化轻量融合网络和进化搜索策略予以实现. 大量实验表明, 所提框架在融合质量、下游任务性能和推理效率方面均具有较强竞争力, 验证了自适应多目标优化对任务感知图像融合的有效性.

局限性. 尽管部署模型较为轻量, 迭代式任务适应和进化搜索使训练过程仍相对复杂. 此外, 学习所得折中依赖选定的下游任务及监督信号. 未来将探索更简洁的优化策略和更广泛的任务设置.

潜在影响. 该框架有望用于视频监控、自动驾驶和遥感等多模态感知应用. 在隐私敏感或安全攸关场景中部署时, 仍需进行审慎评价.

参考文献

- [1] H. Li, X.-J. Wu, and J. Kittler, “MDLatLRR: A novel decomposition method for infrared and visible image fusion,” *IEEE Transactions on Image Processing*, vol. 29, pp. 4733–4746, 2020.
- [2] X. Zhang and Y. Demiris, “Visible and infrared image fusion using deep learning,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 8, pp. 10 535–10 554, 2023.
- [3] W. Zhao, H. Cui, H. Wang, Y. He, and H. Lu, “FreeFusion: Infrared and visible image fusion via cross reconstruction learning,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1–17, 2025.
- [4] R. Liu, Z. Liu, J. Liu, X. Fan, and Z. Luo, “A task-guided, implicitly-searched and meta-initialized deep model for image fusion,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 10, pp. 6594–6609, 2024.
- [5] C. Cheng, T. Xu, Z. Feng, X. Wu, Z. Tang, H. Li, Z. Zhang, S. Atito, M. Awais, and J. Kittler, “One Model for ALL: Low-level task interaction is a key to task-agnostic image fusion,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2025, pp. 28 102–28 112.
- [6] H. Xu, J. Ma, J. Jiang, X. Guo, and H. Ling, “U2Fusion: A unified unsupervised image fusion network,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 1, pp. 502–518, 2020.
- [7] Z. Zhao, H. Bai, J. Zhang, Y. Zhang, S. Xu, Z. Lin, R. Timofte, and L. Van Gool, “CDDFuse: Correlation-driven dual-branch feature decomposition for multi-modality image fusion,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, June 2023, pp. 5906–5916.
- [8] H. Li, T. Xu, X.-J. Wu, J. Lu, and J. Kittler, “LRRNet: A novel representation learning guided fusion network for infrared and visible images,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 45, no. 9, pp. 11 040–11 052, 2023.
- [9] J. Liu, Z. Liu, G. Wu, L. Ma, R. Liu, W. Zhong, Z. Luo, and X. Fan, “Multi-interactive feature learning and a full-time multi-modality benchmark for image fusion and segmentation,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 8115–8124.
- [10] L. Tang, H. Zhang, H. Xu, and J. Ma, “Rethinking the necessity of image fusion in high-level vision tasks: A practical infrared and visible image fusion network based on progressive semantic injection and scene fidelity,” *Information Fusion*, vol. 99, p. 101870, 2023.
- [11] J. Liu, B. Zhang, Q. Mei, X. Li, Y. Zou, Z. Jiang, L. Ma, R. Liu, and X. Fan, “DCEvo: Discriminative cross-dimensional evolutionary learning for infrared and visible image fusion,” in *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*, June 2025, pp. 2226–2235.
- [12] J. Liu, X. Fan, Z. Huang, G. Wu, R. Liu, W. Zhong, and Z. Luo, “Target-aware dual adversarial learning and a multi-scenario multi-modality benchmark to fuse infrared and visible for object detection,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 5802–5811.

- [13] L. Tang, J. Yuan, and J. Ma, "Image fusion in the loop of high-level vision tasks: A semantic-aware real-time infrared and visible image fusion network," *Information Fusion*, vol. 82, pp. 28–42, 2022.
- [14] Z. Liu, J. Liu, B. Zhang, L. Ma, X. Fan, and R. Liu, "PAIF: Perception-aware infrared-visible image fusion for attack-tolerant semantic segmentation," in *Proceedings of the 31st ACM international conference on multimedia*, 2023, pp. 3706–3714.
- [15] J. Chen, J. Ding, and J. Ma, "HitFusion: Infrared and visible image fusion for high-level vision tasks using transformer," *IEEE Transactions on Multimedia*, vol. 26, pp. 10 145–10 159, 2024.
- [16] H. Zhang, X. Zuo, J. Jiang, C. Guo, and J. Ma, "MRFS: Mutually reinforcing image fusion and segmentation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2024, pp. 26 974–26 983.
- [17] Z. Liu, J. Liu, G. Wu, L. Ma, X. Fan, and R. Liu, "Bi-level dynamic learning for jointly multi-modality image fusion and beyond," in *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence*, 2023, pp. 1240–1248.
- [18] H. Bai, J. Zhang, Z. Zhao, Y. Wu, L. Deng, Y. Cui, T. Feng, and S. Xu, "Task-driven image fusion with learnable fusion loss," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025, pp. 7457–7468.
- [19] P. Zhu, Y. Sun, B. Cao, and Q. Hu, "Task-customized mixture of adapters for general image fusion," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2024, pp. 7099–7108.
- [20] H. Li, Z. Yang, Y. Zhang, W. Jia, Z. Yu, and Y. Liu, "MulFS-CAP: Multimodal fusion-supervised cross-modality alignment perception for unregistered infrared-visible image fusion," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 47, no. 5, pp. 3673–3690, 2025.
- [21] H. Li, X.-J. Wu, and J. Kittler, "RFN-Nest: An end-to-end residual fusion network for infrared and visible images," *Information Fusion*, vol. 73, pp. 72–86, 2021.
- [22] H. Li and X.-J. Wu, "DenseFuse: A fusion approach to infrared and visible images," *IEEE Transactions on Image Processing*, vol. 28, no. 5, pp. 2614–2623, 2019.
- [23] Z. Zhao, S. Xu, C. Zhang, J. Liu, J. Zhang, and P. Li, "DIDFuse: deep image decomposition for infrared and visible image fusion," in *Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence*, 2021, pp. 976–976.
- [24] J. Liu, R. Lin, G. Wu, R. Liu, Z. Luo, and X. Fan, "CoCoNet: Coupled contrastive learning network with multi-level feature ensemble for multi-modality image fusion," *International Journal of Computer Vision*, vol. 132, no. 5, pp. 1748–1775, 2024.
- [25] W. Tang, F. He, and Y. Liu, "YDTR: Infrared and visible image fusion via y-shape dynamic transformer," *IEEE Transactions on Multimedia*, vol. 25, pp. 5413–5428, 2022.
- [26] J. Ma, H. Xu, J. Jiang, X. Mei, and X.-P. Zhang, "DDcGAN: A dual-discriminator conditional generative adversarial network for multi-resolution image fusion," *IEEE Transactions on Image Processing*, vol. 29, pp. 4980–4995, 2020.
- [27] Y. Gao, S. Ma, and J. Liu, "DCDR-GAN: A densely connected disentangled representation generative adversarial network for infrared and visible image fusion," *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 33, no. 2, pp. 549–561, 2023.
- [28] Z. Wang, Z. Zhang, W. Qi, F. Yang, and J. Xu, "FreqGAN: Infrared and visible image fusion via unified frequency adversarial learning," *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 35, no. 1, pp. 728–740, 2025.
- [29] J. Yue, L. Fang, S. Xia, Y. Deng, and J. Ma, "Dif-Fusion: Toward high color fidelity in infrared and visible image fusion with diffusion models," *IEEE Transactions on Image Processing*, vol. 32, pp. 5705–5720, 2023.
- [30] J. Liu, L. Sun, T. Ma, C. Yang, Z. Jiang, L. Ma, R. Liu, and X. Fan, "Streaming diffusion model for fast infrared and visible video fusion," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2026, pp. 14 305–14 314.

- [31] Z. Zhao, H. Bai, Y. Zhu, J. Zhang, S. Xu, Y. Zhang, K. Zhang, D. Meng, R. Timofte, and L. Van Gool, “DDFM: Denoising diffusion model for multi-modality image fusion,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2023, pp. 8082–8093.
- [32] A. Sikdar, J. Teotia, and S. Sundaram, “OGP-Net: Optical guidance meets pixel-level contrastive distillation for robust multi-modal and missing modality segmentation,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, no. 7, 2025, pp. 6922–6930.
- [33] Y. Sun, B. Cao, P. Zhu, and Q. Hu, “DetFusion: A detection-driven infrared and visible image fusion network,” in *Proceedings of the 30th ACM international conference on multimedia*, 2022, pp. 4003–4011.
- [34] L. Sun, K. Zhang, F. Zhang, W. Wan, and J. Sun, “Deep rank-n decomposition network for image fusion,” *IEEE Transactions on Multimedia*, 2024.
- [35] L. Tang, J. Yuan, H. Zhang, X. Jiang, and J. Ma, “PIAFusion: A progressive infrared and visible image fusion network based on illumination aware,” *Information Fusion*, vol. 83, pp. 79–92, 2022.
- [36] W. Zhao, S. Xie, F. Zhao, Y. He, and H. Lu, “MetaFusion: Infrared and visible image fusion via meta-feature embedding from object detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 13955–13965.
- [37] N. Li, L. Ma, G. Yu, B. Xue, M. Zhang, and Y. Jin, “Survey on Evolutionary Deep Learning: Principles, algorithms, applications, and open issues,” *ACM Computing Surveys*, vol. 56, no. 2, pp. 1–34, 2023.
- [38] T. Wei, S. Wang, J. Zhong, D. Liu, and J. Zhang, “A Review on Evolutionary Multitask Optimization: Trends and challenges,” *IEEE Transactions on Evolutionary Computation*, vol. 26, no. 5, pp. 941–960, 2022.
- [39] Z. Wang, T. Luo, M. Li, J. T. Zhou, R. S. M. Goh, and L. Zhen, “Evolutionary multi-objective model compression for deep neural networks,” *IEEE Computational Intelligence Magazine*, vol. 16, no. 3, pp. 10–21, 2021.
- [40] F. Song, H. Xing, X. Wang, S. Luo, P. Dai, Z. Xiao, and B. Zhao, “Evolutionary multi-objective reinforcement learning based trajectory control and task offloading in UAV-assisted mobile edge computing,” *IEEE Transactions on Mobile Computing*, vol. 22, no. 12, pp. 7387–7405, 2023.
- [41] X. Liu, Z.-Y. Chai, Y.-Y. Cheng, Y.-L. Li, and T. Li, “Evolutionary multi-objective deep reinforcement learning for task offloading in industrial internet of things,” *IEEE Transactions on Network and Service Management*, vol. 22, no. 5, pp. 5074–5089, 2025.
- [42] L. Ma, N. Li, G. Yu, X. Geng, S. Cheng, X. Wang, M. Huang, and Y. Jin, “Pareto-wise ranking classifier for multiobjective evolutionary neural architecture search,” *IEEE Transactions on Evolutionary Computation*, vol. 28, no. 3, pp. 570–581, 2024.
- [43] Y. Tian, X. Li, H. Ma, X. Zhang, K. C. Tan, and Y. Jin, “Deep reinforcement learning based adaptive operator selection for evolutionary multi-objective optimization,” *IEEE Transactions on Emerging Topics in Computational Intelligence*, vol. 7, no. 4, pp. 1051–1064, 2023.
- [44] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” 2023.
- [45] D. Wang, J. Liu, R. Liu, and X. Fan, “An interactively reinforced paradigm for joint infrared-visible image fusion and saliency object detection,” *Information Fusion*, vol. 98, p. 101828, 2023.